

事前学習済み特徴ゲインモデルによる ヒトの選択的聴取傾向の再現

独自に構築した Common Voice 評価セットを用いた定性的再現

Griffith, Hess & McDermott (2026, Nature Human Behaviour)

研究室ミーティング・単一の事前学習済みチェックポイント・15-20分

ゲイン機構は選択的聴取を説明できるか？

ヒトが直面する問題

騒がしい場所でも、私たちは一人の声に注意し、他の声を無視できる。

モデル (Griffith et al., 2026)

手がかり音声に一致する特徴を強調し、それ以外を抑制する学習済み特徴ゲインを適用する。

論文の主張

単一の最適化されたゲイン機構が、多様な条件における聴取の成功と失敗の両方を予測する。

本研究の目的

著者らの事前学習済みチェックポイントに独自の Common Voice テストセットを入力し、行動傾向が再現されるか検証する。


1試行の流れ

1. Cue — ターゲット話者の手がかり音声
2. Mixture — ターゲット + 妨害音声
3. Report — ターゲット中央の単語を回答

(800語の語彙から選択)

パラメータは固定：再学習ではなく、推論時の行動を検証する。

共通の評価刺激作成パイプライン




アンカー方式 = 先にターゲット語を決め、その語を中心に音声区間を切り出す論文の規則

- 構造的制約：cue と target は同一話者・別録音、妨害話者は別人、ターゲットの性別は均衡。
- 論文準拠の採点：予測がターゲット区間内の語彙内単語のいずれかに一致すれば正答。
- モデル動作確認：クリーン音声 88.6%、+inf で 88.0%（チャンスレベル 0.1%）。

PART 1

妨害話者の性別・競合話者1名

SNRとともに正答率が上昇し、異性話者の方が容易




再現された傾向

- 両条件とも、SNRに伴い単調に上昇。
- 全マスク条件で、異性話者 > 同性話者。
- 差は +9~+18 パーセントポイント。
- +inf では約88%に収束：妨害音声がないため性別差も消失。

同一項目内比較、N=599/597、両耳同一

= 論文 Fig. 2a (同性条件) + Fig. 2b (両条件)

混同の方向は再現したが、値が小さすぎた



混同 = モデルが妨害音声の中の単語を回答

方向は一致：

- SNRが低いほど混同が増える
- 異性より同性の方が混同しやすい

しかし論文より4～5倍低い

原因：妨害音声をランダムに選んだため、中央語の多くが出力語彙外だった。モデルが妨害語を聴き取っても、その語を出力できない。

→ PART 2 では、この問題を刺激設計から修正した。

PART 2・新規実験

妨害話者数・1 / 2 / 4名 + バブルノイズ

総マスクエネルギー一定でも、話者数は影響するか？

ヒトの聴取では、総マスクエネルギーが同じでも競合話が増えるほど難しくなる。

これは情報マスキング、すなわち単なるエネルギー遮蔽ではなく、他者の声との混同による効果である。

したがって、総マスクエネルギーを一定に保ち、声の数だけを変える必要がある。

検証予測：特徴ゲインモデルが情報マスキングを捉えるなら、エネルギー一致条件でも話者数の増加に伴い正答率が低下する。

N=1 は PART 1 と同じ課題・混合方法を用いるため、方向性の内部チェックになる。

条件とネスト化サンプリング

実験条件

妨害なし・1名・2名・4名・8話者バブル・ISSN対照

マスキング条件は $-9 \cdots +3$ dB、妨害なしは $+\infty$ の1点。

同一項目内比較

同じ600ターゲットを全条件 $\times$ SNRで再混合。差はサンプルではなく条件に由来する。

ネスト化サンプリング

各ターゲットで $d1 \cdots d8$ を固定。2名 = $d1, d2$ 、4名 = $d1-d4$ 、バブル = $d1-d8$ 。

→ 2話者条件は、文字どおり1話者条件に1名追加したもの。変わるのは話者数だけ。

アンカー付き妨害音声プール

各妨害録音にも語彙内アンカー語を設定し、ターゲットと同様に切り出した。

- 1,200録音 / 1,200話者
- 男性600 / 女性600
- ターゲット話者との重複 0
- 異なるアンカー語 534語

モデルが妨害語を出力可能になり、混同を測定できる。

ターゲット対総マスクーSNRで変数を分離

- 各妨害音声のRMSを揃え、まず合計して1つの総マスクーを作る。
- 総マスクー全体を $10 \cdot \log_{10}(P_{\text{target}} / P_{\text{masker}}) = \text{SNR}$ となるよう調整し、target + masker を混合。
- → 同じSNRでは、1 / 2 / 4話者の総マスクーエネルギーが等しい。
- 条件間の正答率差は音量では説明できず、「混同しうる声の増加」を反映する。
- 論文の2・4話者条件と同じ中核設計：各音源を揃えて合計後、対総マスクーSNRを設定。
- 8話者バブルは近似：本研究はオンライン加算、論文は作成済み音源を使用。

実行前に加えた2つの統制

話者性別の均衡化 — 重要な交絡

ランダム抽出では P（同性話者を1名以上含む）が N とともに 50% → 99.6% に上昇。

性別効果は大きく（PART 1）、話者数効果と混同される。

対策：d1…d8 を性別交互に配置 → 同性話者数を厳密に 0.5 / 1 / 2 / 4 に統制。

全600ターゲットで確認：ばらつきなし、ネスト維持、本人・重複話者なし。

ISSN対照条件

スペクトルを一致させた定常ノイズ — 無音区間も言語内容もない。


情報マスキングと、単語間の隙間を利用する時間的グリnpingを分離する。

グリnpingが主因なら、隙間のある音声の方が隙間のないノイズより容易なはず。

さらに1話者を one_same / one_diff に分割し、PART 1（Fig. 2a/2b）も内部再現。

競合話者が増えるほどターゲット単語正答率が低下

Experiment 1: Number of distractors



Single pretrained checkpoint · N = 600 trials / 149 target speakers · 95% cluster-bootstrap CI · One-talker pools same- and different-sex trials


正答率（左）：SNRとともに単調増加；1話者統合 > 2話者 > 4話者 ≈ バブル；+inf = 88%。 混同率（右）：マスキングがノイズ様になるほど、特定の妨害語への回答は減少。

論文準拠の採点・1話者条件は性別を統合・149ターゲット話者単位の95%クラスターCI

音声マスキアーは、スペクトル一致定常ノイズより困難

Speech maskers remain harder than matched stationary noise

Pattern is consistent with information masking beyond temporal glimpsing



Paper-compatible target scoring · 95% cluster-bootstrap CI by target speaker

ISSN = スペクトルを一致させた定常ノイズ（無音区間・単語なし）

- 全SNRで、4話者およびバブルの正答率はISSNより低い。
- ISSNは無音区間がない一方、音声にはグリンピング可能な休止がある。
- それでも残る音声の不利は、隙間利用を超えた情報マスキングと整合する。
- ただし証明ではなく支持的証拠：コーパスとマスキアー構成は論文と異なる。

アンカー付きプールにより混同率の過小評価を改善

修正前（ランダム）

7.2%

同性話者・-9 dB の混同率



修正後（アンカー付き）

28.0%

同性話者・-9 dB の混同率

論文

~41%

同条件のおおよその値

論文より5.7倍低い状態から1.5倍低い状態へ — 原因診断は正しかった。

予測と逆の結果も正直に報告：混同率は同性1話者で最も高く、話者数の増加とともに低下した。事前の予測とは逆だが論文とは整合する。声が増えるとマスキングがノイズ様になり、特定の妨害語ではなく無関係な誤答が増える。

結果の信頼性を支える内部整合性チェック

- 妨害なし = 88.0% : PART 1 の +inf アンカーと完全に一致。
 - one_same / one_diff はPART 1の1話者曲線を追従し、2～6ポイント低い（アンカー付き別プールのため想定内）。
 - N=1 は再現済みの単一妨害話者条件に帰着し、方向と形状が一致。
 - 全600ターゲットで性別均衡を確認：同性数は厳密、ネスト維持、本人・重複話者なし。
- 結果は内部的に整合する。今後、Windowsで実行した正確なスクリプトをローカルに保存する必要がある。

再現できたこと



モデル動作（クリーン音声）

88.6%（チャンス 0.1%）



正答率とSNR

両実験で単調に上昇



異性話者 > 同性話者

+9～+18ポイント



話者数増加 → 困難化

1話者統合 > 2話者 > 4話者 ≈ バブル



混同率の方向

低SNR・同性条件で増加



混同率の大きさ

7.2% → 28%へ改善（論文 約41%）

解釈上の境界

コーパスの不一致 (CV $\neq$ SWC) — 最大の限界：

- 本研究は Common Voice、論文の実験1は学習未使用の Spoken Wikipedia (SWC) を使用。
- ターゲット固有ファイルの231/347、プールの703/1,200がCV公式train splitに属する。
- split所属だけでは学習時の実使用を断定できないが、学習未使用データへの汎化とは主張できない。
- 同一パネル内の条件差は有益だが、絶対値と汎化性能には不確実性が残る。
- 話者数に対する混同率は事前基準と逆だった（隠さず報告）。
- バブルは8話者のオンライン加算（論文は作成済み音源）。ネスト維持のための意図的選択。
- 単一チェックポイントのみ。論文の特徴ゲイン曲線は10種類のアーキテクチャを平均。
- 定性的な傾向の再現に限定。両耳同一・独自刺激条件。

今後

次のステップ

- RTX 3070で用いた正確な実行スクリプト、環境、乱数seed、ファイルhashを保存。
- 学習未使用の Spoken Wikipedia から評価セットを再構築し、論文に忠実な再現を行う。
- 論文の作成済みバブル音源と、2・4話者条件の正確な性別構成を使用。
- 10種類すべての特徴ゲインモデルを実行、または単一チェックポイント検証と明示。
- 混合効果モデル／話者クラスターブートストラップを適用し、OSFの曲線と直接比較。

単一の固定済み特徴ゲインモデルで、
SNR・妨害話者の性別・話者数の傾向を定性的に再現した。

ご清聴ありがとうございました